

4-Tu-dien-du-lieu

Data Dictionary — Datathon 2026 Round 1

Miền dữ liệu: thương mại điện tử thời trang (thị trường Việt Nam), 14 file CSV.

Khoảng thời gian lịch sử: 2012-07-04 → 2022-12-31.

Bài toán: dự báo **Revenue** và **COGS** theo ngày cho 2023-01-01 → 2024-07-01 (548 ngày).

Mọi con số dưới đây được kiểm chứng trực tiếp trên file, không suy đoán.

0. Tổng quan các bảng

File	Số dòng	Grain (1 dòng = ?)	Khóa chính	Vai trò
<code>sales.csv</code>	3,833	1 ngày	<code>Date</code>	Target — chuỗi cần dự báo
<code>sample_submission.csv</code>	548	1 ngày	<code>Date</code>	Format nộp bài
<code>orders.csv</code>	646,945	1 đơn hàng	<code>order_id</code>	Fact — header đơn hàng
<code>order_items.csv</code>	714,669	1 dòng sản phẩm trong đơn	<code>(order_id, product_id)</code> ¹	Fact — chi tiết đơn
<code>payments.csv</code>	646,945	1 đơn hàng	<code>order_id</code>	Fact — thanh toán (1:1 với orders)
<code>shipments.csv</code>	566,067	1 đơn hàng	<code>order_id</code>	Fact — vận chuyển (subset của orders)
<code>returns.csv</code>	39,939	1 dòng trả hàng	<code>return_id</code>	Fact — trả hàng
<code>reviews.csv</code>	113,551	1 đánh giá	<code>review_id</code>	Fact — đánh giá sản phẩm
<code>inventory.csv</code>	60,247	1 sản phẩm × 1 tháng	<code>(snapshot_date, product_id)</code>	Fact — snapshot tồn kho cuối tháng
<code>web_traffic.csv</code>	3,652	1 ngày	<code>date</code>	Fact — traffic website

File	Số dòng	Grain (1 dòng = ?)	Khóa chính	Vai trò
customers.csv	121,930	1 khách hàng	customer_id	Dimension
products.csv	2,412	1 SKU	product_id	Dimension
geography.csv	39,948	1 mã zip	zip	Dimension
promotions.csv	50	1 chương trình KM	promo_id	Dimension

¹ Có **16 cặp (order_id, product_id) trùng lặp** (714,669 dòng vs 714,653 cặp distinct) — cần `groupby` hoặc thêm surrogate key khi join. Không ảnh hưởng đến tổng hợp doanh thu.

1. sales.csv — TARGET

Chuỗi thời gian cần dự báo. **Không có ngày trống**: 3,833 ngày liên tục = đúng số ngày distinct trong `orders.order_date`.

Cột	Kiểu	Mô tả
Date	date	Ngày giao dịch. 2012-07-04 → 2022-12-31
Revenue	float	Doanh thu gộp trong ngày
COGS	float	Giá vốn hàng bán trong ngày

⚠ Công thức tái tạo — đã kiểm chứng khớp 100% trên cả 3,833 ngày

```
Revenue(d) = Σ order_items.quantity × order_items.unit_price
COGS(d)    = Σ order_items.quantity × products.cogs
```

với tổng lấy trên **mọi order_items thuộc đơn có orders.order_date = d**.

Ba điểm cực kỳ quan trọng:

- discount_amount KHÔNG bị trừ.** `Revenue` là doanh thu gộp theo giá niêm yết trên dòng đơn. (Giả thuyết "net = qty×price – discount" lệch ở 1,707/3,833 ngày — chính là các ngày có khuyến mãi; giả thuyết "gross" lệch 0 ngày, sai số tối đa 0.0000.)
- KHÔNG lọc theo order_status**. Đơn `cancelled` (59,462 đơn, ~9.2%) vẫn được tính vào doanh thu.
- KHÔNG trừ hàng trả về.** `returns.refund_amount` không tác động tới `sales.csv`.

Sai số kiểm chứng: `Revenue` max diff = 0.0000, `COGS` max diff = 0.0000 trên toàn bộ chuỗi.

Hệ quả cho modeling: bạn có thể tái tạo target ở mức chi tiết bất kỳ — theo category, region, kênh, phân khúc khách hàng — rồi dự báo từng thành phần và cộng lại (hierarchical / bottom-up forecasting). Đây là lợi thế lớn so với chỉ dùng `sales.csv`.

2. `sample_submission.csv` — Format nộp bài

Cột	Kiểu	Mô tả
Date	date	2023-01-01 → 2024-07-01, 548 ngày liên tục
Revenue	float	Giá trị dự báo (file mẫu chứa giá trị placeholder)
COGS	float	Giá trị dự báo

Khoảng dự báo dài **548 ngày (~18 tháng)** — horizon rất xa, đòi hỏi mô hình nắm được xu hướng dài hạn và mùa vụ năm, không thể dựa vào lag ngắn.

3. `orders.csv` — Header đơn hàng

Cột	Kiểu	Mô tả
<code>order_id</code>	int	PK , duy nhất. Miền <code>1 → 834,397</code> nhưng chỉ có 646,945 dòng → khuyết 187,452 giá trị, KHÔNG liên tục . Không dùng làm biến số học, không suy thứ tự thời gian từ ID
<code>order_date</code>	date	Ngày đặt hàng. <code>2012-07-04 → 2022-12-31</code>
<code>customer_id</code>	int	FK → <code>customers.customer_id</code> . 0 giá trị mờ côi
<code>zip</code>	int	FK → <code>geography.zip</code> . 100% trùng với <code>customers.zip</code> của khách hàng đó → cột dư thừa
<code>order_status</code>	enum	Xem phân bố bên dưới
<code>payment_method</code>	enum	<code>credit_card</code> , <code>cod</code> , <code>paypal</code> , <code>bank_transfer</code> , <code>apple_pay</code>
<code>device_type</code>	enum	<code>desktop</code> , <code>mobile</code> , <code>tablet</code>
<code>order_source</code>	enum	<code>direct</code> , <code>email_campaign</code> , <code>organic_search</code> , <code>paid_search</code> , <code>referral</code> , <code>social_media</code>

Phân bố `order_status` :

Status	Số đơn	%	Có bản ghi shipment?	Có bản ghi return?
delivered	516,716	79.9%	516,192 (99.9%)	không
cancelled	59,462	9.2%	0	không
returned	36,142	5.6%	36,113 (99.9%)	36,062 (99.8%)
shipped	13,773	2.1%	13,762 (99.9%)	không
paid	13,577	2.1%	0	không
created	7,275	1.1%	0	không

Trạng thái tuân theo vòng đời hợp lý: created → paid → shipped → delivered → returned , nhánh cancelled .
Chỉ đơn đã shipped trở đi mới có bản ghi vận chuyển; chỉ đơn returned mới có bản ghi trả hàng (100% các dòng returns đều trở tới đơn returned).

4. `order_items.csv` — Chi tiết dòng đơn

Cột	Kiểu	Null	Mô tả
<code>order_id</code>	int	0	FK → <code>orders.order_id</code>
<code>product_id</code>	int	0	FK → <code>products.product_id</code> . 0 giá trị mờ côi
<code>quantity</code>	int	0	Số lượng
<code>unit_price</code>	float	0	Giá bán thực tế tại thời điểm đặt. Chỉ 3/714,669 dòng trùng khớp tuyệt đối với <code>products.price</code> (tỷ lệ trung vị $\text{unit_price}/\text{price} = 0.982$) → giá biến động theo thời gian, <code>products.price</code> chỉ là giá tham chiếu hiện tại
<code>discount_amount</code>	float	0	Số tiền giảm giá của dòng. Tổng 749.6 tr trên gross 16,430.5 tr = 4.56%
<code>promo_id</code>	str	438,353 (61.3%)	FK → <code>promotions.promo_id</code> . 0 mờ côi. → chỉ 38.7% dòng đơn có khuyến mãi
<code>promo_id_2</code>	str	714,463 (99.97%)	Khuyến mãi thứ 2 khi <code>stackable_flag=1</code> . Chỉ 206 dòng có giá trị

Trung bình ~1.10 dòng sản phẩm/đơn (714,669 / 646,945).

5. `payments.csv` — Thanh toán

Cột	Kiểu	Mô tả
<code>order_id</code>	int	PK / FK → <code>orders.order_id</code> . Quan hệ 1:1 — đúng 646,945 dòng, không trùng
<code>payment_method</code>	enum	Lặp lại <code>orders.payment_method</code> → dư thừa
<code>payment_value</code>	float	= $\Sigma(\text{quantity} \times \text{unit_price} - \text{discount_amount})$ của đơn. Kiểm chứng: 0/646,945 sai lệch
<code>installments</code>	int	Số kỳ trả góp: <code>1, 2, 3, 6, 12</code>

Lưu ý: `payment_value` là giá trị **net sau giảm giá** — khác với định nghĩa `Revenue` trong `sales.csv` (gross).
Đừng dùng `payments` để tái tạo target.

6. `shipments.csv` — Vận chuyển

Cột	Kiểu	Mô tả
<code>order_id</code>	int	PK / FK → <code>orders.order_id</code> , duy nhất. 566,067 dòng = 87.5% đơn hàng
<code>ship_date</code>	date	Ngày xuất kho
<code>delivery_date</code>	date	Ngày giao thành công
<code>shipping_fee</code>	float	Phí vận chuyển. Không nằm trong <code>Revenue</code>

Chỉ tồn tại cho đơn có trạng thái `shipped` / `delivered` / `returned`. Feature khai thác được:
`delivery_date - ship_date` (thời gian giao), `ship_date - order_date` (thời gian xử lý) → tương quan với `return_reason = late_delivery`.

7. `returns.csv` — Trả hàng

Cột	Kiểu	Mô tả
<code>return_id</code>	str	PK , <code>RET-XXXXXX</code>
<code>order_id</code>	int	FK → <code>orders.order_id</code> . 36,062 đơn distinct → có đơn trả nhiều dòng
<code>product_id</code>	int	FK → <code>products.product_id</code>
<code>return_date</code>	date	Ngày trả
<code>return_reason</code>	enum	<code>changed_mind</code> , <code>defective</code> , <code>late_delivery</code> , <code>not_as_described</code> , <code>wrong_size</code>
<code>return_quantity</code>	int	Số lượng trả
<code>refund_amount</code>	float	Số tiền hoàn. Không ảnh hưởng <code>sales.csv</code>

100% dòng trả tới đơn có `order_status = 'returned'`.

8. reviews.csv — Đánh giá

Cột	Kiểu	Mô tả
review_id	str	PK , REV-XXXXXXX
order_id	int	FK → orders.order_id , 0 mờ côi. 111,369 đơn distinct (17.2% đơn có review)
product_id	int	FK → products.product_id
customer_id	int	FK → customers.customer_id (suy ra được từ order_id → dư thừa)
review_date	date	Ngày đánh giá
rating	int	1–5
review_title	str	Tiêu đề ngắn (không có phần thân review)

Grain thực tế = (order_id, product_id) duy nhất (113,551 cặp = 113,551 dòng).

9. inventory.csv — Snapshot tồn kho

Grain: **1 sản phẩm × 1 tháng**, chốt vào ngày cuối tháng. 126 tháng (2012-07 → 2022-12), 60,247 dòng.

Cột	Kiểu	Mô tả
snapshot_date	date	Ngày cuối tháng
product_id	int	FK → <code>products.product_id</code>
stock_on_hand	int	Tồn kho cuối kỳ
units_received	int	Nhập trong kỳ
units_sold	int	Bán trong kỳ
stockout_days	int	Số ngày hết hàng trong tháng, 0–28
days_of_supply	float	Số ngày tồn kho đủ bán (max 68,100 → có outlier cực đoan)
fill_rate	float	Tỷ lệ đáp ứng, 0.0667–1. ⚠ Cột suy diễn thuần túy — xem bên dưới
stockout_flag	0/1	40,571 dòng = 67.3%
overstock_flag	0/1	45,942 dòng = 76.3%
reorder_flag	0/1	Luôn = 0 trên toàn bộ 60,247 dòng → cột vô dụng, loại bỏ
sell_through_rate	float	Tỷ lệ bán hết, 0.0004–0.853
product_name , category , segment	str	Denormalized từ products (khớp 100%) → dư thừa
year , month	int	Tách từ <code>snapshot_date</code> → dư thừa

⚠ `fill_rate` = $1 - \text{stockout_days} / 30$, đúng 100% trên cả 60,247 dòng. Đây là hàm xác định của `stockout_days` chứ không phải phép đo độc lập — chỉ nhận 29 giá trị rời rạc. Dùng đồng thời hai cột này tạo đa cộng tuyến hoàn hảo; giữ một cột là đủ. (Mẫu số cố định 30 bất kể tháng có 28/29/31 ngày — thêm một dấu hiệu dữ liệu được sinh tổng hợp.)

⚠ `stockout_flag` và `overstock_flag` chồng lẫn nhau: **30,495 dòng (50.6%) bật CẢ HAI** cờ cùng lúc — vừa hết hàng vừa tồn kho vượt ngưỡng trong cùng một tháng. Chỉ 4,229 dòng (7.0%) không bật cờ nào. Ngữ nghĩa hai cờ này không loại trừ nhau như tên gọi gợi ý; kiểm tra kỹ trước khi dùng làm feature.

⚠ `inventory` chỉ phủ **1,624 / 2,412 SKU (67.3%)** → không ghép được tồn kho cho toàn bộ giao dịch.

10. `web_traffic.csv` — Traffic website

Đúng 1 dòng/ngày, 3,652 ngày: `2013-01-01` → `2022-12-31` .

Cột	Kiểu	Mô tả
<code>date</code>	date	Ngày
<code>sessions</code>	int	Số phiên
<code>unique_visitors</code>	int	Khách duy nhất
<code>page_views</code>	int	Lượt xem trang
<code>bounce_rate</code>	float	Tỷ lệ thoát (giá trị mẫu ~0.005 — thang đo bất thường, cần kiểm tra)
<code>avg_session_duration_sec</code>	float	Thời lượng phiên TB (giây)
<code>traffic_source</code>	enum	 Chi 1 dòng/ngày nên cột này KHÔNG phải phân rã theo nguồn — nó chỉ là nhãn nguồn chiếm ưu thế của ngày đó

 **Bẫy lớn:** dữ liệu chỉ có tới 2022-12-31, **thiếu 6 tháng đầu** so với `sales.csv` (2012-07 → 2012-12) và **không có giá trị nào cho kỳ dự báo 2023–2024**. Muốn dùng làm biến ngoại sinh cho test set thì phải tự dự báo nó trước (rủi ro cộng dồn sai số), hoặc chỉ dùng cho phân tích/validation.

11. `customers.csv` — Dimension khách hàng

Cột	Kiểu	Mô tả
<code>customer_id</code>	int	PK , 121,930 giá trị duy nhất
<code>zip</code>	int	FK → <code>geography.zip</code> . 0 mờ còi
<code>city</code>	str	Denormalized từ <code>geography</code> → dư thừa
<code>signup_date</code>	date	<code>2012-01-17</code> → <code>2022-12-31</code> . ⚠ Không đáng tin — xem cảnh báo bên dưới
<code>gender</code>	enum	<code>Female</code> , <code>Male</code> , <code>Non-binary</code>
<code>age_group</code>	enum	<code>18-24</code> , <code>25-34</code> , <code>35-44</code> , <code>45-54</code> , <code>55+</code>
<code>acquisition_channel</code>	enum	6 giá trị, trùng danh mục với <code>orders.order_source</code> và <code>web_traffic.traffic_source</code>

🚨 `signup_date` mâu thuẫn thời gian — 73.80% đơn hàng

477,453 / 646,945 đơn hàng (73.80%) được đặt TRƯỚC ngày `signup_date` của chính khách hàng đó — bất khả thi về mặt nghiệp vụ. Nguyên nhân gần như chắc chắn: `signup_date` được sinh ngẫu nhiên độc lập với lịch sử giao dịch, không bị ràng buộc phải sớm hơn đơn đầu tiên.

Hệ quả — các feature sau KHÔNG dùng được:

- ❌ Cohort analysis theo tháng đăng ký
- ❌ Thâm niên/tuổi khách hàng tại thời điểm đặt hàng (`order_date - signup_date` âm ở 73.8% trường hợp)
- ❌ Phân biệt khách mới vs khách cũ dựa trên `signup_date`

Thay thế: suy trực tiếp từ lịch sử giao dịch — dùng `MIN(orders.order_date)` theo `customer_id` làm mốc "khách hàng xuất hiện lần đầu". Chỉ số này nhất quán về thời gian và tính được hoàn toàn từ `orders` .

Ghi chú thêm: **31,684 khách (26.0%) chưa từng đặt đơn nào**; chỉ 90,246/121,930 khách có giao dịch. Trung bình 7.17 đơn/khách có *giao dịch* (không phải 5.31 nếu chia cho toàn bộ dimension).

12. `products.csv` — Dimension sản phẩm

Cột	Kiểu	Mô tả
<code>product_id</code>	int	PK , 1 → 2,412, liên tục không đứt đoạn (bảng duy nhất có ID liên tục)
<code>product_name</code>	str	Tên SKU, ví dụ <code>DragonWear MA-01</code> . Chi 2,172 tên distinct / 2,412 dòng — có trùng lặp , xem cảnh báo bên dưới
<code>category</code>	enum	<code>Casual</code> , <code>GenZ</code> , <code>Outdoor</code> , <code>Streetwear</code> . Doanh thu cực lệch: <code>Streetwear</code> chiếm 79.9%
<code>segment</code>	enum	<code>Activewear</code> , <code>All-weather</code> , <code>Balanced</code> , <code>Everyday</code> , <code>Performance</code> , <code>Premium</code> , <code>Standard</code> , <code>Trendy</code> . ⚠️ KHÔNG lồng hoàn toàn trong <code>category</code> — xem bên dưới
<code>size</code>	enum	<code>S</code> , <code>M</code> , <code>L</code> , <code>XL</code>
<code>color</code>	str	10 màu: <code>black</code> , <code>white</code> , <code>red</code> , <code>blue</code> , <code>green</code> , <code>yellow</code> , <code>orange</code> , <code>pink</code> , <code>purple</code> , <code>silver</code>
<code>price</code>	float	Giá niêm yết hiện tại — không dùng được cho lịch sử (khớp <code>unit_price</code> ở 3/714,669 dòng).

Cột	Kiểu	Mô tả
		Phân bố hai đỉnh do lẫn SKU không hoạt động
<code>cogs</code>	float	Giá vốn — dùng trực tiếp để tính <code>COGS</code> target. Biên lợi nhuận gộp lý thuyết TB 26.6% (<i>xem lưu ý</i>)

`cogs` là **hằng số theo sản phẩm, không đổi theo thời gian** — đây là lý do `COGS` tái tạo được chính xác tuyệt đối.

⚠ `segment` **không phải phân cấp con của** `category`

Bảy phân khúc thuộc duy nhất một category, nhưng `Activewear` **xuất hiện ở CẢ** `Casual` **và** `Outdoor`. Số phân khúc mỗi category cũng không đồng đều:

<code>category</code>	Các <code>segment</code>	Số SKU
<code>Streetwear</code>	<code>Everyday</code> (405), <code>Performance</code> (347), <code>Balanced</code> (306), <code>Standard</code> (262)	1,320
<code>Outdoor</code>	<code>Activewear</code> (566), <code>Premium</code> (177)	743
<code>Casual</code>	<code>All-weather</code> (169), <code>Activewear</code> (32)	201
<code>GenZ</code>	<code>Trendy</code> (148)	148

→ **Không được coi `segment` là chi tiết hoá của `category`** khi làm hierarchical forecasting; hai chiều này giao nhau chứ không lồng nhau. Nếu cần phân cấp thật, phải dùng cặp `(category, segment)`.

⚠ **186 tên SKU bị nhân bản với giá mâu thuẫn — và 814 SKU chết**

186 tên sản phẩm ứng với 426 dòng (132 tên có 2 bản, 54 tên có 3 bản). Các bản sao **giống hệt nhau ở** `category`, `segment`, `size`, `color` — chỉ khác `price` và `cogs`, chênh nhau tới hàng trăm lần:

product_id	product_name	category / segment / size / color	price	cogs	Số dòng trong order_items
280	LotusWear UE-01	Streetwear / Performance / S / red	12,596.85	11,967.01	120
380	LotusWear UE-01	Streetwear / Performance / S / red	34.04	21.34	0

Tin tốt: không ảnh hưởng target. Toàn bộ 654 SKU có `price < 100` đều **chưa từng xuất hiện trong** `order_items` → đóng góp đúng **0%** vào cả `Revenue` lẫn `COGS`. Trong mỗi cặp nhân bản, chỉ bản có giá thực mới phát sinh giao dịch.

Nhưng ảnh hưởng mọi thống kê mô tả về giá. Bảng chia làm hai quần thể:

Nhóm	Số SKU	price trung vị	Biên LN lý thuyết trung vị
Hoạt động (có giao dịch)	1,598 (66.3%)	5,505.13	19.78%
Không hoạt động (0 giao dịch)	814 (33.7%)	37.21	38.97%

→ Luôn lọc `product_id IN (SELECT DISTINCT product_id FROM order_items)` trước khi tính bất kỳ thống kê giá/biên lợi nhuận nào.

Lưu ý về con số 26.6%: đây là biên lợi nhuận lý thuyết trung bình trên toàn bộ 2,412 SKU (gồm cả SKU chết). **Biên lợi nhuận gộp thực tế của toàn hệ thống chỉ 13.8%** ($1 - \Sigma \text{COGS} / \Sigma \text{Revenue}$), vì doanh thu tập trung vào `Streetwear` — danh mục có biên thấp:

category	% doanh thu	Biên LN gộp thực tế
Streetwear	79.92%	13.24%
Outdoor	15.18%	16.37%
Casual	2.80%	11.75%
GenZ	2.09%	19.13%

13. `geography.csv` — Dimension địa lý

Cột	Kiểu	Mô tả
zip	int	PK , 39,948 mã
city	str	Thành phố (VD: Hai Phong, Phu Ly)
region	enum	Central , East , West
district	str	Quận/huyện, dạng District #N

14. promotions.csv — Dimension khuyến mãi

50 chương trình, 2013-01-31 → 2022-11-18.

Cột	Kiểu	Null	Mô tả
promo_id	str	0	PK , PROMO-00XX
promo_name	str	0	VD Spring Sale 2013 — có tên mùa vụ, mã hoá được thành feature lịch
promo_type	enum	0	percentage, fixed
discount_value	float	0	% nếu percentage, số tiền nếu fixed
start_date / end_date	date	0	Khoảng hiệu lực (~30 ngày)
applicable_category	str	40 (80%)	Rỗng = áp dụng cho mọi category
promo_channel	enum	0	email, online, ...
stackable_flag	0/1	0	Cho phép cộng dồn KM (tương ứng order_items.promo_id_2)
min_order_value	float	0	Giá trị đơn tối thiểu

Vì promotions phủ toàn bộ 2013–2022 với ngày bắt đầu/kết thúc rõ ràng, đây là **nguồn feature lịch tốt nhất** — và là biến ngoại sinh duy nhất có thể *biết trước* nếu đề bài cung cấp lịch KM 2023–2024. Nếu không, ta có thể suy ra chu kỳ lặp hàng năm từ promo_name.

Tổng kết chất lượng dữ liệu

Điểm mạnh

- Toàn vẹn tham chiếu **hoàn hảo**: 0 khóa ngoại mờ côi trên tất cả các quan hệ đã kiểm tra.
- Hầu như **không có giá trị khuyết**, trừ promo_id / promo_id_2 (khuyết = "không có KM", đúng ngữ nghĩa) và applicable_category.
- Target tái tạo được **chính xác tuyệt đối** từ dữ liệu giao dịch.

Cảnh báo

Sắp theo mức độ nghiêm trọng:

#	Vấn đề	Ảnh hưởng
1	<code>Revenue</code> là gross , không trừ discount, không lọc <code>cancelled</code>	Sai định nghĩa → sai target hoàn toàn
2	<code>customers.signup_date</code> sau <code>order_date</code> ở 73.80% đơn	Mọi feature cohort/thâm niên/khách-mới đều vô hiệu. Thay bằng <code>MIN(order_date)</code> theo khách
3	<code>web_traffic</code> không có dữ liệu 2023–2024	Không dùng trực tiếp làm biến ngoại sinh cho test
4	814/2,412 SKU (33.7%) chưa từng bán, 654 trong đó có giá bất thường <100	Bóp méo mọi thống kê giá/biên LN. Phải lọc trước khi phân tích danh mục
5	16 cặp <code>(order_id, product_id)</code> trùng trong <code>order_items</code>	<code>(order_id, product_id)</code> không phải PK hợp lệ ; join bùng nổ dòng nếu không xử lý
6	<code>segment</code> không lồng trong <code>category</code> (<code>Activewear</code> ở cả <code>Casual</code> lẫn <code>Outdoor</code>)	Sai phân cấp khi làm hierarchical forecasting
7	<code>web_traffic</code> thiếu 6 tháng đầu (2012–H2)	Lệch khoảng thời gian khi join với <code>sales</code>
8	<code>inventory.fill_rate</code> = 1 – <code>stockout_days</code> /30 (khớp 100%)	Cột suy diễn — đa cộng tuyến hoàn hảo, giữ 1 trong 2
9	<code>inventory.stockout_flag</code> + <code>overstock_flag</code> cùng bật ở 50.6% dòng	Ngữ nghĩa hai cờ không loại trừ nhau
10	<code>orders.order_id</code> khuyết 187,452 giá trị (max 834,397 ≠ 646,945 dòng)	ID không liên tục — không dùng làm biến số học
11	<code>inventory.reorder_flag</code> toàn 0	Loại bỏ
12	<code>inventory.days_of_supply</code> max 68,100	Outlier cực đoan, cần winsorize
13	<code>inventory</code> chỉ phủ 67.3% SKU	Không ghép được cho toàn bộ giao dịch
14	<code>products.price</code> không phản ánh giá lịch sử	Luôn dùng <code>order_items.unit_price</code>

#	Vấn đề	Ảnh hưởng
15	Cột denormalized (<code>orders.zip</code> , <code>inventory.category</code> , <code>customers.city</code> , <code>payments.payment_method</code> , <code>reviews.customer_id</code>)	Dư thừa — bỏ qua khi build feature
16	<code>bounce_rate</code> ~0.005, biên độ chỉ 0.0032–0.0058	Thang đo đáng ngờ, gần như hằng số
17	31,684 khách (26.0%) chưa từng mua	<code>customers</code> không phải tập khách đã giao dịch

Dấu hiệu dữ liệu mô phỏng. Nhiều đặc điểm cho thấy đây không phải dữ liệu vận hành thực: toàn vẹn tham chiếu tuyệt đối (0 mờ côi trên 4,815,470 bản ghi kiểm tra), `quantity` phân bố gần như đều hoàn hảo trên 8 mức (mỗi mức 12.4–12.5%), `fill_rate` là hàm xác định của `stockout_days` với mẫu số cố định 30, các trần cứng về lead time (ship ≤ 3 ngày, giao ≤ 7 ngày, trả ≤ 31 ngày, review ≤ 40 ngày), và mùa vụ ngược quy luật bán lẻ thời trang (đỉnh tháng 4–6, đáy tháng 11–1). Các kết luận nghiệp vụ rút ra cần diễn giải thận trọng, không khái quát hoá cho thị trường thực.