

Kịch bản thuyết trình

Kịch bản thuyết trình — Từ điển dữ liệu và Sơ đồ ERD

Người trình bày: sinh viên phụ trách phần mô tả dữ liệu

Thời lượng: 9–10 phút + hỏi đáp

Cách dùng tài liệu này: phần trong khung xám là **thao tác**, không đọc lên.
Phần chữ thường là **lời nói**, đọc gần như nguyên văn được.
Chỗ **in đậm** là chỗ nên nhấn giọng.

CHUẨN BỊ TRƯỚC KHI VÀO

Mở sẵn 3 tab:

- Tab 1 – data-dictionary.md (cuộn sẵn tới đầu file)
- Tab 2 – erd.svg (phóng vừa đủ thấy toàn sơ đồ)
- Tab 3 – quy-trình-kiem-dinh.md (cuộn sẵn tới Bước 5)

KHÔNG mở file .drawio – dễ lỡ tay làm hỏng sơ đồ.

Ghi sẵn 3 con số ra giấy: 73,8% · sai số 0,00 / 3.833 ngày · 93 – 15 – 3 = 75

PHẦN 1 — TỪ ĐIỂN DỮ LIỆU · 6 phút

1.1. Em nhận được gì

► MÀN HÌNH: Tab 1 – data-dictionary.md

Dạ em xin trình bày phần từ điển dữ liệu và sơ đồ ERD.

Nhóm em nhận được **14 tệp CSV, gần 3 triệu dòng, 96 cột**. Nhưng **không có tài liệu nào đi kèm** — không ai nói cho em biết cột nào là khóa, các bảng nối với nhau ra sao, hay cột nào đáng tin.

Nên việc đầu tiên em phải làm là **tự dựng lại tấm bản đồ đó**. Đó chính là từ điển dữ liệu.

1.2. Vấn đề em nhận ra ngay từ đầu

Ban đầu em định đọc tên cột để đoán ý nghĩa — nghe hợp lý mà. Nhưng em thử kiểm tra một cột và giật mình.

Bảng khách hàng có cột `signup_date`, tên nó là "ngày đăng ký tài khoản". Em định dùng nó để tính xem khách gắn bó với shop bao lâu rồi — lấy ngày đặt hàng trừ ngày đăng ký. Đặc trưng này rất hợp lý cho bài toán dự báo.

Nhưng khi chạy thử, em thấy **73,8% đơn hàng có ngày đặt TRƯỚC ngày đăng ký**. Tức là kết quả ra số âm — khách mua hàng trước khi có tài khoản, chuyện không thể xảy ra.

Từ đó em rút ra nguyên tắc làm việc: **tên cột chỉ là gợi ý, không phải bằng chứng**. Cái gì cũng phải kiểm chứng trên dữ liệu thật rồi mới ghi vào tài liệu.

1.3. Cách em làm — bốn bước

Em làm theo bốn bước.

Bước một, em kiểm kê: mỗi tệp có bao nhiêu dòng, mỗi cột kiểu gì, giá trị nằm trong khoảng nào. Với các cột phân loại, em liệt kê hết các giá trị chứ không ghi chung chung là "kiểu chuỗi". Nhờ vậy em mới thấy `order_status` chỉ có đúng 6 giá trị, và chúng xếp thành một vòng đời: tạo đơn → thanh toán → giao hàng → nhận hàng → có thể trả lại, với nhánh hủy đơn.

Bước hai, em kiểm tra khóa chính. Bước này tưởng hiển nhiên nhưng cho em một phát hiện quan trọng — em sẽ nói ở phần sau.

Bước ba, em kiểm tra xem các bảng nối với nhau có sạch không. Ý là: nếu một đơn hàng ghi mã khách là 999, mà bảng khách hàng không có ai mang mã đó, thì dữ liệu bị hỏng.

Bước bốn, em đi tìm những cột **không mang thông tin mới**. Đây là bước tốn công nhất nhưng em thấy giá trị nhất.

1.4. Điều em hiểu ra: không phải cột nào cũng là thông tin

► CUỘN TỐI: mục 9 – inventory.csv

Lúc đầu em nghĩ 96 cột là 96 thông tin. Nhưng làm rồi mới thấy không phải. Em chia được thành **bốn loại**:

Loại một là cột thông tin thật — như số lượng mua, giá bán, ngày đặt hàng. Chỉ loại này mới thực sự có giá trị cho mô hình.

Loại hai là cột khóa ngoại — như `customer_id` trong bảng đơn hàng. Nó chỉ để nối bảng, không phải tính chất của đơn hàng. Có 15 cột như vậy.

Loại ba là cột dư thừa — chép nguyên từ bảng khác. Ví dụ cột `city` trong bảng khách hàng trùng khớp 100% với bảng địa lý.

Loại bốn là cột suy diễn — tính lại được bằng công thức.

1.5. Cách em tìm ra cột suy diễn

Đây là phần quan trọng nhất, nói chậm và kỹ.

Chỗ này em xin nói kỹ vì đây là phần em tâm đắc nhất.

Em nhìn bảng tồn kho, thấy cột `fill_rate` — tỷ lệ đáp ứng đơn hàng. Em để ý nó chỉ nhận rất ít giá trị khác nhau, nên nghi nó không phải một phép đo độc lập.

Em nhìn sang cột bên cạnh là `stockout_days` — số ngày hết hàng trong tháng. Em đoán: **hay là `fill_rate` bằng 1 trừ số ngày hết hàng chia cho 30?**

Em viết công thức đó ra rồi so với dữ liệu thật. **Khớp 100% trên cả 60.247 dòng.** Vậy đúng là cột suy diễn — nó chỉ là cột kia viết theo cách khác.

Em làm tương tự và tìm được thêm bốn cột nữa.

Nhưng em cũng có hai lần đoán sai. Em thử `refund_amount` — tiền hoàn trả — bằng số lượng trả nhân đơn giá. Kết quả chỉ khớp **0,64%**. Em thử `overstock_flag` theo ngưỡng tồn kho, ngưỡng tốt nhất cũng chỉ khớp **83%**. Hai cột đó em kết luận là **không** suy diễn được, giữ nguyên là cột thông tin thật.

Em nêu hai lần đoán sai này vì em nghĩ nó quan trọng: nếu công thức nào cũng khớp 100% thì nghe như em bịa. Có lần sai mới chứng minh em thật sự kiểm tra ạ.

1.6. Vì sao việc này quan trọng

Ban đầu em cũng nghĩ "cột thừa thì kệ nó, để đó có sao đâu". Nhưng em tìm hiểu thì thấy có sao.

Nếu em đưa cả `stockout_days` lẫn `fill_rate` vào mô hình, hai biến này **tương quan hoàn hảo** với nhau vì bản chất là một. Mô hình không phân biệt được biến nào đóng góp gì. Hiện tượng này gọi là **đa cộng tuyến**.

Hậu quả là trọng số mô hình chạy lung tung, và cái biểu đồ "biến nào quan trọng nhất" cho kết quả sai — mô hình có thể xếp hạng cao một biến chỉ vì nó là bản sao của biến khác.

Nên em phải lọc từ bước này, chứ không đợi tới lúc huấn luyện mô hình mới phát hiện.

1.7. Phát hiện lớn nhất

► CUỘN TỐI: mục 1 – sales.csv, phần công thức tái tạo

Phát hiện em thấy giá trị nhất là về chính hai biến nhóm em cần dự báo.

Ban đầu em coi **Revenue** và **COGS** như một hộp đen — có sẵn thì dùng thôi. Nhưng em thắc mắc: **hai con số này ở đâu ra?**

Em thử cộng tất cả dòng hàng của các đơn đặt trong một ngày lại xem có ra bằng không. **Kết quả khớp chính xác tuyệt đối — sai số bằng 0,00 trên cả 3.833 ngày.**

Công thức là: doanh thu bằng tổng số lượng nhân đơn giá, còn giá vốn bằng tổng số lượng nhân giá nhập.

Từ đó em rút ra **ba điều rất dễ hiểu nhầm:**

Một, doanh thu này là **gộp**, không trừ tiền giảm giá — dù giảm giá chiếm 4,56%.

Hai, nó tính **cả đơn đã hủy và đơn bị trả lại**. Nếu loại hai nhóm đó ra thì doanh thu chỉ còn 85%.

Ba, mốc thời gian là **ngày đặt hàng**, không phải ngày giao hay ngày thanh toán.

Điều này quan trọng vì khi nhóm em báo cáo kết quả dự báo, phải nói rõ là đang dự báo **giá trị đặt hàng**, chứ không phải doanh thu thực thu. Hai cái khác nhau.

1.8. Một phát hiện nhỏ nhưng nguy hiểm

Ở bước kiểm tra khóa chính, em thấy bảng **order_items** — chi tiết đơn hàng. Em nghĩ khóa của nó phải là cặp mã đơn và mã sản phẩm, vì mỗi sản phẩm chỉ xuất hiện một lần trong một đơn.

Nhưng khi đếm, em thấy 714.669 dòng mà chỉ có 714.653 cặp khác nhau — **có 16 cặp bị trùng**.

Con số nhỏ nhưng hậu quả lớn: nếu em cứ tin cặp đó là khóa rồi nối bảng, những dòng trùng sẽ **bị nhân lên**, và doanh thu tính ra sẽ bị tính lỗi. Sai này rất khó phát hiện vì nó không báo lỗi gì cả.

1.9. Kết quả phần từ điển

► CUỘN XUỐNG CUỐI FILE: **bảng 17 cảnh báo**

Kết quả cuối cùng, từ điển của em mô tả đầy đủ **96 trường của 14 bảng**. Mỗi cột em ghi năm thứ: kiểu dữ liệu, có phải khóa không, giá trị nằm trong khoảng nào, có thiếu không và **thiếu nghĩa là gì**, cuối cùng là ý nghĩa nghiệp vụ.

Chỗ "thiếu nghĩa là gì" em thấy quan trọng. Ví dụ cột **applicable_category** trong bảng khuyến mại thiếu 80%. Nếu em coi đó là lỗi rồi xóa 40 dòng đó đi thì sai hoàn toàn — **giá trị thiếu ở đây nghĩa là "áp dụng cho mọi danh mục"**, tức nghĩa rộng nhất chứ không phải hẹp nhất.

Ngoài ra em tổng hợp được **17 cảnh báo chất lượng dữ liệu**, xếp theo mức nghiêm trọng, để cả nhóm biết cái nào phải xử lý trước.

PHẦN 2 — SƠ ĐỒ ERD · 3 phút

► MÀN HÌNH: chuyển sang Tab 2 – erd.svg

2.1. Em phải chọn loại sơ đồ trước

Sang phần thứ hai là sơ đồ ERD. Việc đầu tiên em phải quyết là **vẽ loại nào**, vì có hai loại hay bị gọi lẫn nhau.

Một loại vẽ các bảng kèm cột khóa chính khóa ngoại — cái đó trả lời câu hỏi "dữ liệu lưu ở bảng nào", gọi là mức logic.

Loại còn lại là **ERD mức khái niệm**, dùng ký hiệu Chen: thực thể là hình chữ nhật, quan hệ là hình thoi, thuộc tính là hình elip. Nó trả lời "dữ liệu là gì và liên quan với nhau ra sao".

Quy trình thiết kế cơ sở dữ liệu đi theo thứ tự ERD trước rồi mới ánh xạ sang mô hình quan hệ, nên em vẽ ERD mức khái niệm.

2.2. Điều em hiểu ra khi vẽ

► CHỈ VÀO: hình thoi "đặt" giữa CUSTOMERS và ORDERS

Lúc đầu em định vẽ y hệt cấu trúc tệp CSV — có cột gì vẽ cột đó. Nhưng làm rồi mới hiểu **ERD không phải bản chép lại cấu trúc tệp**.

Ví dụ bảng `orders` có cột `customer_id`. Trong ERD, cột này **biến mất** — thay bằng hình thoi "đặt" này đây.

Lý do là hình thoi đó **chính là** câu "đơn hàng thuộc về khách hàng". Nếu em vẽ thêm cột `customer_id` vào nữa thì em đang nói cùng một điều **hai lần**.

Nói cách khác, `customer_id` không phải một tính chất của đơn hàng như ngày đặt hay trạng thái — nó chỉ là **cơ chế kỹ thuật** để nối bảng. Mà mô hình khái niệm thì không mô tả cơ chế.

Tổng cộng **15 cột khóa ngoại đã biến thành 15 mối quan hệ**.

2.3. Cách em chứng minh sơ đồ không sai sót

► Nếu có bảng, viết lên: $93 - 15 - 3 = 75$

Vẽ xong em tự hỏi: làm sao chắc mình không bỏ sót cột nào, cũng không bịa thêm cột nào?

Em làm một phép đối soát: **93 cột của 13 tệp, trừ 15 cột khóa ngoại đã thành quan hệ, trừ 3 cột chép nguyên từ bảng khác, bằng 75 thuộc tính**.

Em đếm số hình elip trên sơ đồ được **đúng 75**. Nghĩa là mỗi cột đều có chỗ đi: hoặc thành thuộc tính, hoặc thành quan hệ, hoặc bị loại có lý do ghi rõ.

2.4. Bản số em đo chứ không đoán

► **CHỈ VÀO:** một đường đôi và một đường đơn trên sơ đồ

Chỗ hai bảng nối nhau, em phải ghi là 1:1 hay 1:N. Em không đoán mà đếm thật.

Ví dụ quan hệ giữa dòng hàng và đánh giá: em đếm được 113.551 đánh giá ứng **đúng** 113.551 cặp khác nhau — không cặp nào lặp lại, nên mỗi dòng hàng có tối đa **một** đánh giá, bản số là 1:1.

Còn trả hàng thì 39.939 dòng trên 39.937 cặp — có dòng bị trả nhiều lần, nên là 1:N.

Ngoài ra sơ đồ còn thể hiện **mức độ tham gia**. Đường đôi nghĩa là bắt buộc — 100% đơn hàng đều có dòng hàng và đều có bản ghi thanh toán. Đường đơn nghĩa là tùy chọn — chỉ 87,5% đơn có giao vận, vì đơn bị hủy thì không bao giờ được giao.

PHẦN 3 — BẢNG CHỨNG VÀ CHỐT · 1 phút

► MÀN HÌNH: chuyển sang Tab 3 – quy-trình-kiem-dinh.md, Bước 5

Toàn bộ những con số em vừa trình bày đều **kiểm chứng lại được**. Em có tài liệu ghi 9 bước kiểm định, mỗi bước gồm đoạn mã và kết quả thật khi chạy.

► CHỈ VÀO: khối code phía trên và khối kết quả phía dưới

Đây là bước phát hiện cột suy diễn — bên trên là mã, bên dưới là kết quả in ra. Thầy/cô có thể chạy lại để kiểm chứng ạ.

► MÀN HÌNH: quay lại Tab 2 – sơ đồ ERD

Tóm lại, sản phẩm em hoàn thành gồm **từ điển dữ liệu mô tả 96 trường kèm 17 cảnh báo chất lượng**, và **sơ đồ ERD với 13 thực thể, 75 thuộc tính, 15 quan hệ**.

Toàn bộ số liệu đều kiểm chứng được bằng cách chạy lại trên dữ liệu gốc. Đây là cơ sở để nhóm em bước sang giai đoạn xây dựng đặc trưng và mô hình dự báo.

Em xin hết ạ. Mong thầy/cô góp ý.

PHỤ LỤC A — Câu hỏi dự phòng

Vì sao 14 tệp mà sơ đồ chỉ có 13 thực thể?

Dạ tệp `sample_submission.csv` là khuôn dạng nộp kết quả dự báo, chứa 548 ngày tương lai với giá trị chỉ mang tính minh họa. Đó là quy ước kỹ thuật của cuộc thi chứ không phải thực thể nghiệp vụ, nên em không đưa vào mô hình khái niệm. Nó vẫn được mô tả đầy đủ trong từ điển dữ liệu ạ.

Vì sao khóa ngoại không xuất hiện trên sơ đồ?

Vì đây là ERD mức khái niệm. Liên kết giữa các thực thể đã do hình thoi quan hệ biểu diễn rồi; vẽ thêm cột khóa ngoại là mô tả trùng một thứ hai lần. Khóa ngoại chỉ xuất hiện sau bước ánh xạ sang mô hình quan hệ ạ.

Thực thể yếu là gì?

Là thực thể không tự định danh được, phải mượn khóa của thực thể chủ. Giống như nói "phòng số 3" thì vô nghĩa nếu không nói rõ phòng số 3 của tòa nhà nào ạ. Bộ dữ liệu này có 4 thực thể yếu, trong đó `ORDER_ITEMS` là vì em phát hiện 16 cặp khóa bị trùng nên nó không có khóa hợp lệ.

Bản số và mức độ tham gia khác nhau ra sao?

Bản số trả lời một bên có bao nhiêu bản thể ứng với một bản thể bên kia, ghi bằng số 1 hoặc N. Mức độ tham gia trả lời có bắt buộc mọi bản thể đều tham gia quan hệ không, thể hiện bằng đường đôi hay đường đơn. Ví dụ `ORDERS` với `SHIPMENTS` là 1:1 nhưng phía `ORDERS` vẽ đường đơn, vì chỉ 87,5% đơn có giao vận ạ.

Bộ dữ liệu này có phải dữ liệu thực tế không?

Em nghĩ là dữ liệu mô phỏng ạ. Có nhiều dấu hiệu: toàn vẹn tham chiếu tuyệt đối trên hơn 4,8 triệu bản ghi, số lượng mua phân bố đều gần như hoàn hảo trên 8 mức, `fill_rate` là hàm xác định của `stockout_days` với mẫu số cố định 30, và mùa vụ ngược quy luật bán lẻ thời trang. Nên các kết luận nghiệp vụ cần diễn giải thận trọng ạ.

Em dùng công cụ gì?

Em dùng Python với thư viện `pandas` để kiểm định dữ liệu, và draw.io để vẽ sơ đồ ạ.

Khi gặp câu không biết

Đừng bịa số. Nói thẳng: "Điểm này em chưa kiểm tra ạ. Em có script kiểm định chạy lại được, em sẽ chạy và báo cáo thầy/cô sau." — Câu này an toàn tuyệt đối vì bạn **có script thật**.

PHỤ LỤC B — Giấy nhớ số liệu

QUY MÔ	
14 tệp · 2.960.736 bản ghi · 96 trường	
Lịch sử: 04/07/2012 – 31/12/2022 (3.833 ngày, không thiếu ngày nào)	
Dự báo: 01/01/2023 – 01/07/2024 (548 ngày)	
BA CON SỐ PHẢI THUỘC	
73,8%	đơn đặt trước ngày đăng ký
Sai số 0,00 / 3.833 ngày	tái tạo biến mục tiêu
93 – 15 – 3 = 75	đối soát thuộc tính ERD
KIỂM ĐỊNH	
Toàn vẹn tham chiếu: 15 quan hệ · 4.815.470 bản ghi · 0 mờ côi	
Cột suy diễn:	5 công thức xác nhận · 2 giả thuyết bị bác bỏ (refund_amount 0,64% · overstock_flag 83%)
SƠ ĐỒ ERD	
13 thực thể · 75 thuộc tính · 15 quan hệ	
4 thực thể yếu · 1 thực thể suy diễn · 11 thuộc tính suy diễn	
PHÁT HIỆN KHÁC	
order_items trùng:	16 cặp (order_id, product_id)
SKU chưa từng bán:	814/2.412 (33,7%)
Khách chưa từng mua:	31.684/121.930 (26,0%)
Cảnh báo chất lượng:	17 mục