

Kịch bản thuyết trình Notebook

Kịch bản thuyết trình bằng Notebook

Tệp trình chiếu: Dictionary-va-ERD.ipynb (hoặc bản HTML)

Thời lượng: 10 phút + hỏi đáp

Cách dùng: khung xám là **thao tác cuộn màn hình**, không đọc lên.
Chữ thường là **lời nói**, đọc gần như nguyên văn được.
Chỗ in đậm là chỗ nhấn giọng.

CHUẨN BỊ

Mở sẵn 2 tab:

- Tab 1 – Dictionary-va-ERD.html (nhấp đúp file trên máy)
- Tab 2 – Link notebook trên GitHub (dự phòng nếu file lỗi)

Phóng chữ tới mức cả phòng nhìn được: Ctrl và dấu +
Cuộn sẵn về đầu trang.

Nguyên tắc khi nói: notebook đã có sẵn code và kết quả, nên **đừng đọc code**.
Chỉ tay vào **kết quả** rồi giải thích ý nghĩa. Code chỉ để chứng minh con số không phải gõ tay.

MỞ ĐẦU · 1 phút

► MÀN HÌNH: đầu notebook – phần "Vấn đề" và "Nguyên tắc làm việc"

Dạ em xin trình bày phần em phụ trách là **từ điển dữ liệu và sơ đồ ERD**.

Em làm dưới dạng notebook, tức là mỗi kết luận em nêu đều nằm **ngay dưới đoạn mã tạo ra nó**. Như vậy thầy/cô có thể kiểm chứng ngay là con số em nói không phải gõ tay vào.

Vấn đề ban đầu của em là: nhóm nhận được **14 tệp CSV, gần 3 triệu dòng, 96 cột**, nhưng **không có tài liệu nào đi kèm**. Không ai nói cho em biết cột nào là khóa, các bảng nối nhau ra sao, cột nào đáng tin.

► CHỈ VÀO: khung trích dẫn "Không mô tả bất kỳ điều gì chưa kiểm chứng..."

Nên em đặt ra một nguyên tắc và giữ suốt quá trình: **tên cột chỉ là gợi ý, không phải bằng chứng**. Cái gì cũng phải chạy kiểm tra trên dữ liệu thật rồi mới ghi vào tài liệu.

Em xin đi qua chín bước em đã làm.

BƯỚC 1 — KIỂM KÊ CẤU TRÚC · 30 giây

► CUỘN TỐI: Bước 1, bảng kết quả 14 dòng

Bước đầu em chỉ đơn giản là đếm: mỗi bảng bao nhiêu dòng, bao nhiêu cột.

► CHỈ VÀO: dòng TONG phía trên bảng

Tổng lại là gần 3 triệu dòng và 96 cột.

Từ đây em phân được 14 bảng thành bốn nhóm: nhóm ghi sự kiện giao dịch, nhóm danh mục, nhóm chuỗi thời gian đã tổng hợp sẵn, và một tệp kỹ thuật chỉ là khuôn dạng nộp bài chứ không phải dữ liệu thật.

BƯỚC 2 — KHÓA CHÍNH · 1 phút

► CUỘN TỐI: Bước 2, ô code kiểm tra `order_items`

Bước hai em kiểm tra khóa chính — tức cột nào định danh duy nhất một dòng.

Với hầu hết bảng thì đúng như em nghĩ. Nhưng đến bảng `order_items` — chi tiết đơn hàng — thì có chuyện.

Em nghĩ khóa của nó phải là **cặp mã đơn và mã sản phẩm**, vì mỗi sản phẩm chỉ nên xuất hiện một lần trong một đơn.

► CHỈ VÀO: dòng kết quả "=> CO 16 CAP BI TRUNG"

Nhưng em đếm ra **714.669 dòng** mà chỉ có **714.653 cặp** khác nhau — tức **16 cặp bị trùng**.

Con số nhỏ nhưng hậu quả lớn ạ. Nếu em cứ tin cặp đó là khóa rồi nối bảng, những dòng trùng sẽ **bị nhân lên**, và doanh thu tính ra bị tính lỗi. Cái sai này **không báo lỗi gì cả** nên rất khó phát hiện.

Đây cũng là căn cứ để sau này em xếp `ORDER_ITEMS` làm **thực thể yếu** trên sơ đồ.

BƯỚC 3 — TOÀN VỆN THAM CHIẾU · 1 phút

► CUỘN TỐI: Bước 3, bảng 15 dòng quan hệ

Bước ba em kiểm tra xem các bảng nối với nhau có "sạch" không.
Ý là thế này: nếu một đơn hàng ghi mã khách là 999, mà bảng khách hàng không có ai mang mã đó, thì gọi là **bản ghi mồ côi** — dữ liệu bị hỏng, nối bảng sẽ mất dữ liệu.

► CHỈ VÀO: cột "Mo coi" toàn số 0, và dòng TONG phía trên

Em kiểm tra **15 quan hệ, tổng hơn 4,8 triệu bản ghi** — **kết quả không có bản ghi mồ côi nào**.
Nghĩa là mọi phép nối bảng đều an toàn, nhóm em không cần bước làm sạch khóa.

► CUỘN XUỐNG: bảng "Do do phu nguoc lai"

Em còn đo thêm chiều ngược lại: bao nhiêu phần trăm bản ghi ở bảng cha thực sự được dùng tới.
Ví dụ **100% đơn hàng đều có dòng hàng và có thanh toán**, nhưng **chỉ 87,5% đơn có giao vận** — vì đơn bị hủy thì không bao giờ rời kho.
Con số này về sau em dùng để quyết định vẽ **đường đôi hay đường đơn** trên sơ đồ ERD.

BƯỚC 4 — CỘT DƯ THỪA · 30 giây

▶ CUỘN TỐI: Bước 4, bảng 4 dòng

Bước bốn em tìm những cột chỉ là **bản sao chép nguyên từ bảng khác**.

▶ CHỈ VÀO: cột "Ty le trung" toàn 100

Bốn cặp em kiểm tra đều trùng khớp **100%**. Ví dụ cột thành phố trong bảng khách hàng chép y nguyên từ bảng địa lý — nó không mang thông tin gì mới.

BƯỚC 5 — CỘT SUY DIỄN · 2 phút

Đây là phần quan trọng nhất. Nói chậm, nói kỹ.

► CUỘN TỐI: Bước 5, ô code hàm `thu_gia_thuyet`

Bước năm là bước em tâm đắc nhất.

Em nhìn bảng tồn kho, thấy cột `fill_rate` — tỷ lệ đáp ứng đơn hàng. Em để ý nó chỉ nhận rất ít giá trị khác nhau, nên nghĩ nó **không phải một phép đo độc lập**.

Em nhìn sang cột bên cạnh là số ngày hết hàng trong tháng, rồi đoán: *hay là `fill_rate` bằng 1 trừ số ngày hết hàng chia cho 30?*

Em viết công thức đó ra rồi so với dữ liệu thật.

► CHỈ VÀO: bảng kết quả, dòng `fill_rate`

Khớp 100% trên cả 60.247 dòng. Vậy đúng là cột suy diễn — nó chỉ là cột kia viết theo cách khác.

Em làm tương tự và tìm được thêm bốn cột nữa.

► CHỈ VÀO: dòng `refund_amount` — 0,64%

Nhưng em cũng có lần đoán sai. Em thử cột tiền hoàn trả bằng số lượng trả nhân đơn giá — kết quả chỉ khớp **0,64%**. Giả thuyết bị bác bỏ, nên em giữ nguyên cột đó là cột thông tin thật.

Em nêu lần thất bại này vì em nghĩ nó quan trọng: **nếu công thức nào cũng khớp 100% thì nghe như em bịa**. Có lần sai mới chứng minh em thật sự kiểm tra ạ.

Vì sao phải làm việc này

Ban đầu em cũng nghĩ "cột thừa thì kệ nó, để đó có sao đâu". Nhưng tìm hiểu thì thấy có sao.

Nếu đưa cả hai cột vào mô hình, chúng **tương quan hoàn hảo** với nhau vì bản chất là một. Mô hình không phân biệt được biến nào đóng góp gì — hiện tượng này gọi là **đa cộng tuyến**. Hậu quả là trọng số chạy lung tung, và biểu đồ "biến nào quan trọng nhất" cho kết quả sai.

Nên phải lọc từ bước mô tả dữ liệu, chứ không đợi tới lúc huấn luyện mới phát hiện.

BƯỚC 6 — CÔNG THỨC BIẾN MỤC TIÊU · 2 phút ★ ★

► CUỘN TỐI: Bước 6, ô code dựng lại sales.csv

Bước sáu là phát hiện em thấy giá trị nhất.

Ban đầu em coi hai biến cần dự báo — doanh thu và giá vốn — như một **hộp đen**, có sẵn thì dùng thôi. Nhưng em thắc mắc: **hai con số này ở đâu ra?**

Em thử cộng tất cả dòng hàng của các đơn đặt trong một ngày lại, xem có ra bằng con số trong tệp không.

► CHỈ VÀO: ba dòng kết quả — sai số 0.0 và 3833/3833

Kết quả khớp chính xác tuyệt đối — sai số bằng 0,00 trên cả 3.833 ngày.

Công thức là: doanh thu bằng tổng số lượng nhân đơn giá, còn giá vốn bằng tổng số lượng nhân giá nhập.

Từ đó em rút ra **ba điều rất dễ hiểu** nhằm:

Một, doanh thu này là **gộp** — không trừ tiền giảm giá, dù giảm giá chiếm 4,56%.

Hai, nó tính **cả đơn đã hủy và đơn bị trả lại**. Nếu loại hai nhóm đó ra thì doanh thu chỉ còn 85%.

Ba, mốc thời gian là **ngày đặt hàng**, không phải ngày giao hay ngày thanh toán.

► CUỘN XUỐNG: ô kiểm chứng ba điều trên

Đây là phần em chạy để kiểm chứng đúng ba điều vừa nói.

Điều này quan trọng vì khi nhóm em báo cáo kết quả dự báo, phải nói rõ đang dự báo **giá trị đặt hàng**, chứ không phải doanh thu thực thu. Hai cái khác nhau tới 17% ạ.

BƯỚC 7 — BẢN SỐ QUAN HỆ · 1 phút

► CUỘN TỐI: Bước 7, bảng bản số

Bước bảy em xác định các bảng nối nhau theo kiểu 1:1 hay 1:N. Em không đoán mà **đếm thật**.

► CHỈ VÀO: dòng ORDER_ITEMS -> REVIEWS

Ví dụ quan hệ giữa dòng hàng và đánh giá: em đếm được **113.551 đánh giá ứng đúng 113.551 cặp khác nhau** — không cặp nào lặp lại. Nghĩa là mỗi dòng hàng có tối đa **một** đánh giá, nên bản số là **1:1**.

Còn trả hàng thì 39.939 dòng trên 39.937 cặp — có dòng bị trả nhiều lần, nên là **1:N**.

► CUỘN XUỐNG: ô kiểm chứng cặp (order_id, product_id)

Ở đây em còn kiểm chứng một điều quan trọng cho việc vẽ sơ đồ. Bảng trả hàng có hai cột: mã đơn và mã sản phẩm. Nhìn qua tưởng là hai quan hệ riêng.

► CHỈ VÀO: kết quả "lech: 0"

Nhưng em kiểm tra thì thấy hai cột đó **luôn đi thành cặp**, và mọi cặp đều nằm trọn trong bảng dòng hàng — **không lệch dòng nào**.

Nghĩa là khách trả lại "*hai cái áo size M màu đỏ trong đơn số 5*" — đó là **một dòng hàng cụ thể**, chứ không phải trả đơn số 5 và trả sản phẩm X như hai việc riêng biệt.

BƯỚC 8 — ĐỐI SOÁT · 45 giây

► CUỘN TỐI: Bước 8

Vẽ sơ đồ xong em tự hỏi: **làm sao chắc mình không bỏ sót cột nào, cũng không bịa thêm cột nào?**
Nên em làm một phép đối soát.

► CHỈ VÀO: khối kết quả $93 - 15 - 3 = 75$

93 cột của 13 tệp, trừ 15 cột khóa ngoại đã biến thành quan hệ, trừ 3 cột chép nguyên từ bảng khác, bằng 75 thuộc tính.
Em đếm số hình elip trên sơ đồ được **đúng 75**.
Nghĩa là mỗi cột đều có chỗ đi: hoặc thành thuộc tính, hoặc thành quan hệ, hoặc bị loại có lý do ghi rõ.
Không có ngoại lệ ạ.

BƯỚC 9 — NHẤT QUÁN NGHIỆP VỤ · 1 phút

► CUỘN TỐI: Bước 9

Bước cuối em kiểm tra những mâu thuẫn về mặt logic — loại lỗi mà nhìn cấu trúc thì không thấy.
Bảng khách hàng có cột ngày đăng ký tài khoản. Em định dùng nó để tính xem khách gắn bó với shop bao lâu rồi — lấy ngày đặt hàng trừ ngày đăng ký. Đặc trưng này rất hợp lý cho bài toán dự báo.

► CHỈ VÀO: kết quả 73.8%

Nhưng em chạy thử thì thấy **73,8% đơn hàng có ngày đặt TRƯỚC ngày đăng ký**. Tức là kết quả ra số âm — khách mua hàng trước khi có tài khoản, chuyện không thể xảy ra.
Nên em kết luận cột này **không dùng được** cho bất kỳ đặc trưng nào. Thay vào đó em đề xuất dùng ngày đặt hàng đầu tiên của mỗi khách, suy trực tiếp từ bảng đơn hàng.
Đây chính là ví dụ rõ nhất cho nguyên tắc em nói ở đầu: **tên cột chỉ là gợi ý, không phải bằng chứng**.

SƠ ĐỒ ERD • 2 phút

► CUỘN TỐI: phần "Sơ đồ ERD" – bảng 4 quy tắc

Kết quả chín bước trên được em chuyển thành sơ đồ theo **bốn quy tắc**.

Quy tắc khó hiểu nhất là quy tắc đầu tiên: **khóa ngoại không được vẽ thành thuộc tính**.

► CUỘN XUỐNG: hình sơ đồ ERD

► CHỈ VÀO: hình thoi "đặt" giữa CUSTOMERS và ORDERS

Ví dụ bảng đơn hàng trong tệp CSV có cột `customer_id`. Nhưng trong sơ đồ, cột này **biến mất** — thay bằng hình thoi "đặt" này đây.

Lý do là hình thoi đó **chính là** câu "đơn hàng thuộc về khách hàng". Nếu em vẽ thêm cột `customer_id` vào nữa thì em đang nói cùng một điều **hai lần**.

Nói cách khác, `customer_id` không phải một tính chất của đơn hàng như ngày đặt hay trạng thái — nó chỉ là **cơ chế kỹ thuật** để nối bảng. Mà mô hình khái niệm thì không mô tả cơ chế.

Tổng cộng **15 cột khóa ngoại đã biến thành 15 mối quan hệ**.

► CHỈ VÀO: một hình chữ nhật viền đôi (ORDER_ITEMS)

Bốn hình chữ nhật **viền đôi** là thực thể yếu — không tự định danh được, phải mượn khóa của thực thể chủ. Giống như nói "phòng số 3" thì vô nghĩa nếu không nói của tòa nhà nào.

► CHỈ VÀO: vài elip nét đứt trong INVENTORY

Còn các elip **nét đứt** này là 11 thuộc tính suy diễn em tìm được ở Bước 5.

TỔNG KẾT · 45 giây

► CUỘN TỐI: phần "Tổng kết", bảng sản phẩm và bảng kiểm định

Tóm lại sản phẩm em hoàn thành gồm:

Từ điển dữ liệu mô tả 96 trường của 14 bảng, kèm **17 cảnh báo chất lượng dữ liệu** xếp theo mức nghiêm trọng.

Sơ đồ ERD với **13 thực thể, 75 thuộc tính, 15 quan hệ**.

► CHỈ VÀO: bảng "Bốn cảnh báo quan trọng nhất"

Và bốn cảnh báo em muốn nhóm lưu ý khi bước sang phần mô hình hóa: định nghĩa đúng biến mục tiêu, không

dùng cột ngày đăng ký, loại bỏ 11 cột suy diễn, và thêm khóa thay thế cho bảng chi tiết đơn.

Toàn bộ số liệu trong notebook này đều chạy lại được. Em xin hết ạ, mong thầy/cô góp ý.

PHỤ LỤC — CÂU HỎI DỰ PHÒNG

Notebook này chạy mất bao lâu?

Dạ khoảng một đến hai phút, vì phải nạp gần 3 triệu dòng ạ. Em đã chạy sẵn nên kết quả hiển thị luôn, nhưng nếu thầy/cô muốn em chạy lại thì em chọn Kernel rồi Restart and Run All.

Vì sao 14 tệp mà sơ đồ chỉ có 13 thực thể?

Tệp `sample_submission.csv` là khuôn dạng nộp kết quả dự báo, chứa ngày tương lai với giá trị chỉ mang tính minh họa. Đó là quy ước kỹ thuật chứ không phải thực thể nghiệp vụ, nên em không đưa vào mô hình khái niệm ạ.

Vì sao khóa ngoại không xuất hiện trên sơ đồ?

Vì đây là ERD mức khái niệm. Liên kết đã do hình thoi quan hệ biểu diễn rồi; vẽ thêm cột khóa ngoại là mô tả trùng. Khóa ngoại chỉ xuất hiện sau bước ánh xạ sang mô hình quan hệ ạ.

Thực thể yếu là gì?

Là thực thể không tự định danh được, phải mượn khóa của thực thể chủ. Giống như "phòng số 3" thì vô nghĩa nếu không nói của tòa nhà nào. Bộ dữ liệu này có 4 thực thể yếu ạ.

Bản số và mức độ tham gia khác nhau ra sao?

Bản số trả lời một bên có bao nhiêu bản thể ứng với một bản thể bên kia, ghi bằng số 1 hoặc N. Mức độ tham gia trả lời có bắt buộc mọi bản thể đều tham gia không, thể hiện bằng đường đôi hay đường đơn. Ví dụ đơn hàng với giao vận là 1:1 nhưng phía đơn hàng vẽ đường đơn, vì chỉ 87,5% đơn có giao vận ạ.

Bộ dữ liệu này có phải dữ liệu thực tế không?

Em nghĩ là dữ liệu mô phỏng ạ. Có nhiều dấu hiệu: toàn vẹn tham chiếu tuyệt đối trên hơn 4,8 triệu bản ghi, số lượng mua phân bố đều gần như hoàn hảo, và một cột là hàm xác định của cột khác với mẫu số cố định 30. Nên các kết luận nghiệp vụ cần diễn giải thận trọng ạ.

Khi gặp câu không biết

Đừng bịa số. Nói thẳng: "*Điểm này em chưa kiểm tra ạ. Notebook của em chạy lại được, em sẽ bổ sung và báo cáo thầy/cô sau.*"

GIẤY NHỚ SỐ LIỆU

BA CON SỐ PHẢI THUỘC	
16 cặp trùng	trong order_items -> không có khoa hợp lệ
Sai số 0,00 / 3.833 ngày	tái tạo biến mục tiêu
73,8%	đơn đặt trước ngày đăng ký
QUY MÔ	
14 tệp	• 2.960.736 bản ghi • 96 trường
Lịch sử 04/07/2012 - 31/12/2022	(3.833 ngày)
Dự báo 01/01/2023 - 01/07/2024	(548 ngày)
KIỂM ĐỊNH	
15 quan hệ	• 4.815.470 bản ghi • 0 mờ côi
5 công thức xác nhận	• 1 giả thuyết bác bỏ (refund_amount 0,64%)
Đối soát 93 - 15 - 3	= 75
SƠ ĐỒ ERD	
13 thực thể	• 75 thuộc tính • 15 quan hệ
4 thực thể yếu	• 1 thực thể suy diễn • 11 thuộc tính suy diễn
PHÁT HIỆN KHÁC	
SKU chưa từng bán	814/2.412 (33,7%)
Khách chưa từng mua	31.684/121.930 (26,0%)
Cảnh báo chất lượng	17 mục