

Huong dan doc Notebook

Hướng dẫn đọc Notebook [Dictionary-va-ERD.ipynb](#)

Mục đích: hiểu từng ô trong notebook để trình bày tự tin, không phải học thuộc.

Mỗi phần gồm ba lớp: **Code làm gì** → **Kết quả** → **Nói gì với giảng viên**.
Phần chữ nghiêng là lời nói, đọc gần như nguyên văn được.

Tổng quan

Notebook có **43 ô**: 27 ô chữ giải thích, **16 ô code** chạy thật. Mạch đi theo **9 bước kiểm định**, kết thúc bằng sơ đồ ERD và bảng tổng kết.

Nguyên tắc thiết kế: **mỗi kết luận nằm ngay dưới đoạn code tạo ra nó** — để chứng minh con số không phải gõ tay vào.

Thời gian chạy lại toàn bộ: **20 giây**.

Ô đầu — Nạp dữ liệu

Code làm gì: đọc 14 tệp CSV vào bộ nhớ, cất vào một cuốn từ điển tên `bang`. Từ đó gọi `bang['orders']` là lấy được bảng đơn hàng.

Kết quả: `Da nạp 14 bang`

Nói gì: "Ô này chỉ nạp dữ liệu, các ô sau đều dùng lại từ đây."

Bước 1 — Kiểm kê cấu trúc

Code làm gì: đếm số dòng và số cột của từng bảng.

Kết quả: bảng 14 dòng, phía trên có dòng tổng 2.960.736 dòng | 96 cột.

Ý nghĩa: biết quy mô để ước lượng khối lượng công việc, và để phân 14 bảng thành 4 nhóm.

Nói gì: "Bước đầu em chỉ đếm. Từ đây em phân được 14 bảng thành bốn nhóm: bảng ghi sự kiện giao dịch, bảng danh mục, bảng chuỗi thời gian đã tổng hợp sẵn, và một tệp kỹ thuật."

Bước 2 — Xác định khóa chính

Có hai ô code.

Ô thứ nhất — kiểm tra 8 bảng

Code làm gì: với mỗi bảng, hỏi "cột này có duy nhất không?" bằng lệnh `is_unique`.

Kết quả: bảng 8 dòng, cột cuối toàn `True`.

Ô thứ hai — kiểm tra `order_items`

Code làm gì: đếm số dòng, rồi đếm số cặp `(order_id, product_id)` khác nhau. Nếu hai con số bằng nhau thì cặp đó là khóa hợp lệ.

Kết quả:

```
order_items co 714,669 dong
nhung chi     714,653 cap khac nhau
=> CO 16 CAP BI TRUNG
```

Ý nghĩa: bảng này **không có khóa tự nhiên hợp lệ**.

Nói gì: "Em nghĩ khóa của bảng chi tiết đơn phải là cặp mã đơn và mã sản phẩm. Nhưng đếm ra thì có 16 cặp bị trùng. Nếu tin đó là khóa rồi nối bảng, những dòng trùng sẽ bị nhân lên và doanh thu tính ra bị tính lố — mà không báo lỗi gì cả."

Đây cũng là căn cứ xếp `ORDER_ITEMS` làm **thực thể yếu** trên sơ đồ ERD.

Bước 3 — Toàn vẹn tham chiếu

Có hai ô code.

Ô thứ nhất — đếm bản ghi mồ cô

Bản ghi mồ cô là dòng dữ liệu trở tới một thứ không tồn tại. Ví dụ đơn hàng ghi mã khách là 999999 nhưng bảng khách hàng không có ai mang mã đó.

Code làm gì: khai báo danh sách 15 cặp quan hệ, mỗi cặp gồm *cột con* và *cột cha*. Với mỗi cặp, đếm xem có bao nhiêu giá trị ở bảng con không tìm thấy ở bảng cha. Dòng cốt lõi:

```
mo_coi = (~con.isin(set(cot_cha))).sum()
```

Dấu ~ nghĩa là "không thuộc".

Kết quả: bảng 15 dòng, cột **Mo coi** **toàn số 0**, tổng **4.815.470 bản ghi | 0 mồ cô**.

Nói gì: "Em kiểm tra 15 quan hệ trên hơn 4,8 triệu bản ghi, không có bản ghi mồ cô nào. Nghĩa là mọi phép nối bảng đều an toàn, nhóm em không cần bước làm sạch khóa."

Ô thứ hai — đo độ phủ ngược lại

Code làm gì: tính xem bao nhiêu phần trăm bản ghi ở bảng cha **thực sự được dùng tới**.

Kết quả: bảng 6 dòng, cột cuối ghi **TOÀN BỘ** hoặc **BỘ PHẬN**.

Đo lường	Tỷ lệ	Kết luận
Đơn có dòng hàng	100%	Toàn bộ → đường đôi
Đơn có thanh toán	100%	Toàn bộ → đường đôi
Đơn có giao vận	87,5%	Bộ phận → đường đơn
Khách từng đặt hàng	74,0%	Bộ phận → đường đơn
Sản phẩm từng bán	66,3%	Bộ phận → đường đơn
Dòng hàng có khuyến mại	38,7%	Bộ phận → đường đơn

Ý nghĩa: con số này quyết định vẽ **đường đôi** hay **đường đơn** trên sơ đồ ERD.

Nói gì: "Bước này cho em căn cứ để vẽ mức độ tham gia. 100% đơn có dòng hàng nên vẽ đường đôi; chỉ 87,5% đơn có giao vận nên vẽ đường đơn, vì đơn bị hủy thì không bao giờ rời kho."

Bước 4 — Cột dư thừa

Code làm gì: nối hai bảng lại rồi so hai cột với nhau xem giống nhau bao nhiêu phần trăm.

Kết quả: bảng 4 dòng, cột **Ty le trung** **toàn 100**.

Cột dư thừa	Chép từ
orders.zip	customers.zip
payments.payment_method	orders.payment_method
customers.city	geography.city
inventory.product_name	products.product_name

Nói gì: "Bốn cột này chép nguyên từ bảng khác, trùng khớp 100%, không mang thông tin gì mới."

Bước 5 — Cột suy diễn

Đây là ô quan trọng nhất notebook. Nói kỹ nhất ở đây.

Code làm gì: định nghĩa một hàm `thu_gia_thuyet` — nhận vào *cột thật* và *công thức đoán*, rồi so khớp trên toàn bộ dữ liệu bằng `np.isclose`. Nếu khớp trên 99,9% thì kết luận là cột suy diễn.

Sau đó gọi hàm đó **6 lần** với 6 giả thuyết khác nhau.

Kết quả:

Cột	Tỷ lệ khớp	Kết luận
<code>fill_rate</code>	100%	SUY DIEN
<code>stockout_flag</code>	100%	SUY DIEN
<code>sell_through_rate</code>	100%	SUY DIEN
<code>days_of_supply</code>	100%	SUY DIEN
<code>payment_value</code>	100%	SUY DIEN
<code>refund_amount</code>	0,64%	KHONG suy dien duoc

Nói gì:

"Em nghi cột `fill_rate` không phải phép đo độc lập. Em đoán nó bằng 1 trừ số ngày hết hàng chia 30, viết công thức ra rồi so — khớp 100% trên cả 60.247 dòng.

Nhưng em cũng có lần đoán sai. Em thử tiền hoàn trả bằng số lượng trả nhân đơn giá, chỉ khớp 0,64%. Giả thuyết bị bác bỏ nên em giữ nguyên cột đó là cột thông tin thật.

Em nêu lần thất bại này vì nếu công thức nào cũng khớp 100% thì nghe như em bịa. Có lần sai mới chứng minh em thật sự kiểm tra ạ."

Vì sao quan trọng: nếu đưa cả `stockout_days` lẫn `fill_rate` vào mô hình, hai biến tương quan hoàn hảo với nhau sẽ gây **đa cộng tuyến** — trọng số bất ổn định và biểu đồ tầm quan trọng đặc trưng cho kết quả sai lệch.

Bước 6 — Công thức biến mục tiêu ★ ★

Có hai ô code.

Ô thứ nhất — dựng lại `sales.csv`

Code làm gì: nối bảng chi tiết đơn với bảng sản phẩm (để lấy giá vốn) và bảng đơn hàng (để lấy ngày). Rồi tính `rev = quantity × unit_price` và `cog = quantity × cogs`, gộp theo ngày đặt hàng, so với `sales.csv` gốc.

Kết quả:

```
Revenue: sai so tuyệt đối lớn nhất = 0.0
COGS    : sai so tuyệt đối lớn nhất = 0.0
Số ngày khớp chính xác: 3833 / 3833
```

Bên dưới còn hiện 5 dòng đầu của bảng so sánh — cột `Revenue` và `rev` giống hệt nhau.

Nói gì: "Ban đầu em coi hai biến cần dự báo như hộp đen, có sẵn thì dùng thôi. Nhưng em thắc mắc chúng ở đâu ra, nên thử cộng tất cả dòng hàng của các đơn đặt trong một ngày lại. Kết quả khớp chính xác tuyệt đối — sai số bằng 0,00 trên cả 3.833 ngày."

Ô thứ hai — kiểm chứng ba điều

Code làm gì: in ra tổng doanh thu gộp, tổng giảm giá, và tỷ lệ còn lại nếu loại đơn hủy và đơn trả.

Kết quả: giảm giá chiếm 4,56%, và nếu loại đơn hủy cùng đơn trả thì chỉ còn 85,25%.

Nói gì: "Ba điều rút ra: doanh thu là gộp không trừ giảm giá; tính cả đơn hủy và đơn trả; mốc thời gian là ngày đặt hàng. Nghĩa là khi báo cáo kết quả dự báo, phải nói rõ đang dự báo giá trị đặt hàng chứ không phải doanh thu thực thu."

Bước 7 — Bản số quan hệ

Có hai ô code.

Ô thứ nhất — đo bản số

Code làm gì: với mỗi cặp bảng, đếm số dòng và số cặp khóa khác nhau. Nếu hai số bằng nhau thì quan hệ 1:1; nếu số dòng lớn hơn thì 1:N.

Kết quả:

Quan hệ	Đo được	Bản số
ORDERS → ORDER_ITEMS	1–5 dòng/đơn	1:N
ORDERS → PAYMENTS	646.945 = 646.945	1:1 tuyệt đối
ORDERS → SHIPMENTS	566.067 / 646.945 đơn	1:1, tham gia bộ phận
ORDER_ITEMS → RETURNS	39.939 dòng / 39.937 cặp	1:N
ORDER_ITEMS → REVIEWS	113.551 dòng / 113.551 cặp	1:1

Nói gì: "Em không đoán mà đếm. Đánh giá có 113.551 dòng ứng đúng 113.551 cặp khác nhau — không cặp nào lặp lại, nên mỗi dòng hàng có tối đa một đánh giá, bản số 1:1. Còn trả hàng thì 39.939 dòng trên 39.937 cặp, có dòng bị trả nhiều lần nên là 1:N."

Ô thứ hai — kiểm chứng cặp khóa

Code làm gì: tạo tập hợp các cặp (order_id, product_id) của ba bảng, rồi kiểm tra tập của returns và reviews có nằm trọn trong tập của order_items không.

Kết quả: cả hai đều True , lech: 0 .

Nói gì: "Bảng trả hàng có hai cột mã đơn và mã sản phẩm, nhìn qua tưởng là hai quan hệ riêng. Nhưng em kiểm tra thì hai cột luôn đi thành cặp và cùng trỏ tới một dòng hàng cụ thể, không lệch dòng nào.

Khách trả lại 'hai cái áo size M màu đỏ trong đơn số 5' — đó là một dòng hàng, chứ không phải trả đơn số 5 và trả sản phẩm X như hai việc riêng biệt."

Bước 8 — Đối soát

Code làm gì: lấy tổng số cột trừ đi cột của tệp kỹ thuật, rồi trừ tiếp 15 cột khóa ngoại và 3 cột sao chép.

Kết quả:

```
93 cot (13 tep)
- 15 cot khoa ngoai    (da thanh quan he)
- 3  cot sao chep      (thuoc ve PRODUCTS)
= 75 thuoc tinh
```

```
So elip dem duoc tren so do ERD: 75 => KHOP
```

Nói gì: "Vẽ xong em tự hỏi làm sao chắc mình không bỏ sót cột nào, cũng không bịa thêm cột nào. Nên em làm phép đối soát này. Mỗi cột đều có chỗ đi: hoặc thành thuộc tính, hoặc thành quan hệ, hoặc bị loại có lý do ghi rõ."

Bước 9 — Nhất quán nghiệp vụ

Có hai ô code.

Ô thứ nhất — `signup_date`

Code làm gì: nối đơn hàng với khách hàng, đổi hai cột về kiểu ngày, rồi đếm xem bao nhiêu đơn có ngày đặt **nhỏ hơn** ngày đăng ký.

Kết quả: `Don dat TRUOC ngay dang ky: 477,453 / 646,945 = 73.8 %`

Nói gì: "Em định dùng cột ngày đăng ký để tính thâm niên khách hàng — lấy ngày đặt trừ ngày đăng ký. Nhưng chạy thử thì 73,8% đơn có ngày đặt trước ngày đăng ký, tức kết quả ra số âm. Khách mua hàng trước khi có tài khoản, chuyện không thể xảy ra. Nên cột này không dùng được cho bất kỳ đặc trưng nào."

Ô thứ hai — sản phẩm và khách hàng chết

Kết quả: 31.684 khách chưa từng mua (26,0%), 814/2.412 sản phẩm chưa từng bán (33,7%), trong đó 654 sản phẩm có giá bất thường dưới 100.

Phần Sơ đồ ERD

Ô chữ trước đó có bảng 4 quy tắc chuyển từ kết quả 9 bước sang sơ đồ:

Quy tắc	Căn cứ	Kết quả trên sơ đồ
1. Khóa ngoại không vẽ thành thuộc tính	Bước 3	15 cột FK → 15 hình thoi
2. Không có khóa hợp lệ → thực thể yếu	Bước 2	4 hình chữ nhật viền đôi
3. Tính lại được bằng công thức → suy diễn	Bước 4, 5, 6	11 elip nét đứt
4. Không phải thực thể nghiệp vụ → loại	Phân tích	Bỏ <code>sample_submission</code> + 3 cột

Ô code chỉ có 2 dòng — nhưng hiển thị tệp `docs/erd.svg`.

Nói gì khi sơ đồ hiện ra: "Quy tắc khó hiểu nhất là quy tắc đầu tiên — khóa ngoại không được vẽ thành thuộc tính. Bảng đơn hàng có cột mã khách, nhưng trong sơ đồ cột này biến mất, thay bằng hình thoi 'đặt'. Vì hình thoi đó chính là câu 'đơn hàng thuộc về khách hàng' — vẽ thêm cột nữa là nói cùng một điều hai lần."

Tổng kết

Ô chữ cuối có **ba bảng**: sản phẩm hoàn thành, kết quả kiểm định, và bốn cảnh báo cho bước mô hình hóa.

Nói gì: "Tóm lại sản phẩm em hoàn thành gồm từ điển dữ liệu mô tả 96 trường kèm 17 cảnh báo chất lượng, và sơ đồ ERD với 13 thực thể, 75 thuộc tính, 15 quan hệ. Toàn bộ số liệu đều chạy lại được. Đây là cơ sở để nhóm em bước sang giai đoạn xây dựng đặc trưng và mô hình dự báo."

Ba ô đáng dừng lâu nhất

Ô	Vì sao
Bước 5 — cột suy diễn	Có cả thành công lẫn thất bại → chứng minh phương pháp có kiểm chứng
Bước 6 — công thức target	Sai số 0,00 là con số mạnh nhất, không ai cãi được
Bước 9 — <code>signup_date</code>	Ví dụ sinh động nhất về "tên cột không đáng tin"

Nếu bị cắt giờ, giữ ba ô này là đủ cho thấy chiều sâu công việc.

Giấy nhớ số liệu

QUY MÔ

14 tệp · 2.960.736 bản ghi · 96 trường
Lịch sử 04/07/2012 – 31/12/2022 (3.833 ngày, không thiếu ngày nào)
Dự báo 01/01/2023 – 01/07/2024 (548 ngày)

BA CON SỐ PHẢI THUỘC

16 cặp trùng trong order_items -> không có khóa hợp lệ
Sai số 0,00 / 3.833 ngày tái tạo biến mục tiêu
73,8% đơn đặt trước ngày đăng ký

KIỂM ĐỊNH

15 quan hệ · 4.815.470 bản ghi · 0 mờ côi
5 công thức xác nhận · 1 giả thuyết bác bỏ (refund_amount 0,64%)
Đối soát 93 – 15 – 3 = 75

SƠ ĐỒ ERD

13 thực thể · 75 thuộc tính · 15 quan hệ
4 thực thể yếu · 1 thực thể suy diễn · 11 thuộc tính suy diễn

PHÁT HIỆN KHÁC

SKU chưa từng bán 814/2.412 (33,7%)
Khách chưa từng mua 31.684/121.930 (26,0%)
Cảnh báo chất lượng 17 mục

THỜI GIAN CHẠY LẠI NOTEBOOK: 20 giây